

Αναπαράσταση αριθμών στα ψηφιακά συστήματα και φίλτρα

Όπως περιγράφεται με λεπτομέρεια στην οικεία ενότητα, η διαδικασία του κβαντισμού *στρογγυλοποιεί* την τιμή του κάθε δείγματος προς τα επάνω ή προς τα κάτω, έτσι ώστε αυτή να ταυτιστεί με την τιμή κάποιου επιπέδου κβαντισμού, προκειμένου τελικά να κωδικοποιηθεί στο δυαδικό σύστημα. Επιπλέον, το γεγονός πως όλα τα ψηφιακά συστήματα χαρακτηρίζονται από επεξεργαστές που περιλαμβάνουν καταχωρητές *πεπερασμένου μήκους*, επιβάλλει την πραγματοποίηση των πάσης φύσεως υπολογισμών, όχι με άπειρη, αλλά με *πεπερασμένη* ακρίβεια η οποία εξαρτάται από το *μήκος των καταχωρητών* που χρησιμοποιούνται για την αποθήκευση των αριθμών, τον *τύπο της αναπαράστασης* που έχει υιοθετηθεί (για παράδειγμα, αναπαράσταση *προσημασμένων αριθμών* ή *συμπληρώματος ως προς δύο*), καθώς και τον *τύπο της αριθμητικής* που χρησιμοποιείται (για παράδειγμα, αριθμητική σταθερής ή κινητής υποδιαστολής). Για τον λόγο αυτό και παρά το γεγονός πως η αναλυτική παρουσίαση των τύπων αναπαράστασης αριθμητικών μεγεθών σε έναν ηλεκτρονικό υπολογιστή, μπορεί να βρεθεί σε οποιοδήποτε εισαγωγικό βιβλίο πληροφορικής, ας παρουσιάσουμε συνοπτικά σε αυτό το σημείο, για λόγους πληρότητας, τη βασική θεωρία που σχετίζεται με αυτούς τους δύο τύπους αναπαράστασης.

Αναπαράσταση σταθερής υποδιαστολής

Από τα βασικά μαθηματικά είναι γνωστό, πως τα ψηφία που εμφανίζονται στη συμβολοσειρά η οποία περιγράφει τον κάθε αριθμό, αποτελούν *τους συντελεστές του γραμμικού συνδυασμού των δυνάμεων της βάσης του θεσιακού συστήματος στο οποίο είναι εκπεφρασμένος αυτός ο αριθμός* και η τιμή του οποίου είναι η τιμή του αριθμού. Γνωρίζουμε επίσης, πως στην επιστήμη της πληροφορικής, εκτός από το *δεκαδικό* σύστημα που χρησιμοποιείται παντού και πάντα, χρησιμοποιείται κατά κύριο λόγο το *δυαδικό* σύστημα αρίθμησης, ενώ αρκετά συχνά χρησιμοποιούνται επίσης, το *οκταδικό* και το *δεκαεξαδικό* σύστημα. Στην γενική περίπτωση, οι αριθμοί που χρησιμοποιούνται, διαθέτουν τόσο *ακέραιο* όσο και *κλασματικό* μέρος, με τα ψηφία που βρίσκονται πριν από το σύμβολο της υποδιαστολής (το οποίο ας σημειωθεί, πως *δεν υλοποιείται με φυσικό τρόπο* σε έναν υπολογιστή) να σχετίζονται με θετικές δυνάμεις του 2 (σε αυτή την περιγραφή, η μελέτη μας περιορίζεται αποκλειστικά στο δυαδικό σύστημα, αν και τα όσα αναφέρονται εδώ, ισχύουν με τις κατάλληλες τροποποιήσεις σε κάθε αριθμητικό σύστημα) και τα ψηφία που βρίσκονται μετά από αυτό το σύμβολο να σχετίζονται με *αρνητικές* δυνάμεις του 2 (κάτι που φυσικά ισχύει για όλα τα αριθμητικά συστήματα και για τη βάση που τα περιγράφει). Θεωρώντας για παράδειγμα τον αριθμό 101010.110101 αυτός, ως γραμμικός συνδυασμός δυνάμεων του 2, διατυπώνεται ως

$$1 \times 2^5 + 0 \times 2^4 + 1 \times 2^3 + 0 \times 2^2 + 1 \times 2^1 + 0 \times 2^0 + 1 \times 2^{-1} + 1 \times 2^{-2} + 0 \times 2^{-3} + 1 \times 2^{-4} + 0 \times 2^{-5} + 1 \times 2^{-6}$$

και δεν είναι δύσκολο να διαπιστωθεί, πως αντιστοιχεί στον δεκαδικό αριθμό 42.828125. Γενικεύοντας την παραπάνω περιγραφή, εάν ένας αριθμός L μήκους K bits εκπεφρασμένος σε ένα αριθμητικό σύστημα με βάση r , αποτελείται από M ψηφία για το ακέραιο μέρος (που βρίσκονται στα αριστερά της υποδιαστολής) και από N ψηφία για το κλασματικό μέρος (που βρίσκονται στα δεξιά της υποδιαστολής), μπορεί να αναπαρασταθεί με τη μορφή

$$L = (d_{-M}, d_{-M+1}, \dots, d_{-1}, d_0, d_1, d_2, \dots, d_{N-1}, d_N) = \sum_{i=-M}^N d_i r^{-i} \quad (1)$$

όπου b_i οποιοδήποτε από τα ψηφία του χρησιμοποιούμενου αριθμητικού συστήματος που λαμβάνει τιμές στην περιοχή $0 \leq d_i \leq (r - 1)$, ενώ r είναι η *βάση* του συστήματος. Στην περίπτωση του δεκαδικού συστήματος είναι $r = 10$, ενώ τα ψηφία που χρησιμοποιούνται είναι τα $\{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$, ενώ στην περίπτωση του δυαδικού συστήματος είναι $r = 2$ ενώ τα ψηφία που χρησιμοποιούνται είναι τα $\{0, 1\}$. Στην ορολογία της επιστήμης της πληροφορικής, το καθένα από αυτά τα ψηφία χαρακτηρίζεται ως *bit* (*binary digit*) και κατά συνέπεια ο κάθε δυαδικός αριθμός περιγράφεται από μία *συμβολοσειρά από bits πεπερασμένου μήκους* K με την αποθήκευση του καθενός από αυτά τα bits, να στηρίζεται στη χρήση μιας διάταξης που είναι γνωστή ως *flip-flop* και η οποία μπορεί να βρεθεί σε δύο καταστάσεις εκ των οποίων η μία κατάσταση αναπαριστά το 0, ενώ η άλλη αναπαριστά το 1. Δεν είναι δύσκολο να γίνει αντιληπτό, πως οι καταχωρητές στους οποίους αποθηκεύονται αυτές οι τιμές, αποτελούνται από μία ομάδα τέτοιων διατάξεων τοποθετημένων η μία μετά την άλλη, με το *πλήθος αυτών των διατάξεων να υπαγορεύει και το μήκος του καταχωρητή*. Από το σύνολο των bits που σχηματίζουν έναν δυαδικό αριθμό, το πρώτο από αριστερά bit έχει την *μικρότερη* συνεισφορά στην τιμή του αριθμού που είναι η $2^0 = 1$ και για το λόγο αυτό είναι γνωστό ως το *λιγότερο σημαντικό bit* (Least Significant Bit, LSB), ενώ το πρώτο από δεξιά bit έχει την *πιο μεγάλη* συνεισφορά στην τιμή του αριθμού που είναι ίση με 2^{K-1} και για το λόγο αυτό είναι γνωστό ως το *περισσότερο σημαντικό bit* (Most Significant Bit, MSB). Στην πιο απλή περίπτωση, όλα τα K bits του αριθμού χρησιμοποιούνται για την αναπαράσταση της τιμής του, ενώ δεν υποστηρίζεται πρόσημο και κλασματικό μέρος, οπότε θα είναι $K = M$ και $N = 0$. Αυτοί οι αριθμοί είναι γνωστοί ως *μη προσημασμένοι ακέραιοι*. Το πλήθος των δυνατών συνδυασμών που μπορούν να προκύψουν από K bits, είναι 2^K και κατά συνέπεια, η περιοχή τιμών για τους αριθμούς που κωδικοποιούνται με K bits, είναι η $[0, 2^K - 1]$. Για παράδειγμα, για την τιμή $K = 8$ θα έχουμε $2^8 = 256$ και κατά συνέπεια οι μη προσημασμένοι ακέραιοι αριθμοί που κωδικοποιούνται με $K = 8$ bits, ανήκουν στην περιοχή τιμών $[0, 255]$. Από την άλλη πλευρά, εάν δεν χρησιμοποιείται καθόλου ακέραιο, αλλά *μόνο κλασματικό μέρος*, δηλαδή εάν είναι $K = N$ και $M = 0$, η περιοχή τιμών στην οποία ανήκουν οι αριθμοί που κωδικοποιούνται με αυτόν τον τρόπο, είναι η $[0, 1 - 2^{-N}]$. Τέλος, στην περίπτωση κατά την οποία ο αριθμός διαθέτει *τόσο ακέραιο όσο και κλασματικό μέρος*, η κατάσταση είναι παρόμοια, αν και σε κάθε περίπτωση, μπορούμε να αναπαραστήσουμε τον αριθμό χρησιμοποιώντας την αναπαράσταση μόνο του κλασματικού μέρους, διαιρώντας τον με τον συντελεστή 2^M . Σε περιπτώσεις κατά τις οποίες η τιμή του αριθμού είναι *μεγαλύτερη* από τη

μέγιστη τιμή ή *μικρότερη* από την ελάχιστη τιμή που μπορεί να κωδικοποιηθεί με K bits, ανακύπτει μία κατάσταση η οποία αντίστοιχα χαρακτηρίζεται ως *υπερχείλιση* (overflow) ή *ανεπάρκεια* (underflow) και η οποία αποτελεί πηγή σφάλματος.

Από την άλλη πλευρά, η αναπαράσταση των αρνητικών αριθμών, μπορεί να πραγματοποιηθεί με τρεις διαφορετικούς τρόπους οι οποίοι σε γενικές γραμμές είναι οι εξής:

- Η *αναπαράσταση πρόσημου - μεγέθους*, στην οποία το πρώτο από δεξιά bit, δηλαδή το πιο σημαντικό bit χρησιμοποιείται για την αναπαράσταση του πρόσημου (με την τιμή 0 να υποδηλώνει πως ο αριθμός είναι θετικός και την τιμή 1 να υποδηλώνει πως ο αριθμός είναι αρνητικός) και κατά συνέπεια, για την αναπαράσταση της τιμής του αριθμού χρησιμοποιούνται τα υπόλοιπα $K - 1$ bits. Με άλλα λόγια, σε αυτή την αναπαράσταση, ένας αριθμός x εκφράζεται ως $s_x x_1 x_2 x_3 \cdots x_n$ με το πρώτο bit s_x να αναπαριστά το πρόσημο του αριθμού και τα bits $x_1 x_2 x_3 \cdots x_n$ να αναπαριστούν την τιμή του. Για λόγους που σχολιάζονται στη συνέχεια, συνήθως οι αριθμοί είναι εκπεφρασμένοι ως *κλασματικοί αριθμοί* - δηλαδή έχουν μόνο κλασματικό μέρος ή ισοδύναμα, έχουν κλιμακωθεί με τον κατάλληλο τρόπο, ώστε να λαμβάνουν τιμές στο διάστημα $(-1, 1)$ - και κατά συνέπεια, σε αυτόν τον τύπο αναπαράστασης, οι θετικοί αριθμοί αναπαρίστανται ως $0.xxxxxx$ ενώ οι αρνητικοί αριθμοί αναπαρίστανται ως $1.xxxxxx$ όπου $xxxxxx$ είναι μία συμβολοσειρά από bits του κατάλληλου μήκους. Με άλλα λόγια, ο δυαδικός αριθμός $s_x x_1 x_2 x_3 \cdots x_n$ έχει τιμή $x = x_1 2^{-1} + x_2 2^{-2} + \cdots + x_n 2^{-n}$ εάν είναι $s_x = 0$ και τιμή $x = -(x_1 2^{-1} + x_2 2^{-2} + \cdots + x_n 2^{-n})$ εάν είναι $s_x = 1$.
- Η *αναπαράσταση του συμπληρώματος ως προς 1*, στην οποία οι αρνητικοί αριθμοί x αναπαρίστανται ως $2 - 2^{-L} - |x|$, όπου L είναι το επονομαζόμενο μήκος λέξης που ορίζεται ως το πλήθος των bits που βρίσκονται δεξιά από το σημείο της υποδιαστολής. Λαμβάνοντας υπόψη πως η δυαδική αναπαράσταση του αριθμού $2 - 2^{-L}$ είναι ένας δυαδικός αριθμός μήκους $L + 1$ bits, όλα τα bits του οποίου έχουν την τιμή 1, όπως εύκολα μπορεί να αποδειχθεί, το συμπλήρωμα ως προς 1 ενός αρνητικού αριθμού μπορεί να υπολογιστεί *εκφράζοντας τον αριθμό ως έναν αριθμό μήκους $L + 1$ bits* (κάτι που σημαίνει πως εάν αναπαρίστανται από λιγότερα bits, θα πρέπει να προσθέσουμε το κατάλληλο πλήθος μηδενικών τιμών πριν το περισσότερο σημαντικό bit), έτσι ώστε να καταστήσουμε το μήκος του ίσο με $L + 1$ και στη συνέχεια προχωρώντας σε *αντιστροφή* των ψηφίων του (κάτι που σημαίνει πως τα bits με τιμή 1 τίθενται στην τιμή 0, και αντίστροφα). Σε μία ισοδύναμη περιγραφή, η αναπαράσταση του συμπληρώματος ως προς 1 ενός αρνητικού αριθμού, συνίσταται στην *αντιστροφή των bits που χρησιμοποιούνται για την αναπαράσταση της απόλυτης τιμής του* και χρησιμοποιώντας ένα επιπλέον bit για το πρόσημο με τον τρόπο που το κάναμε προηγουμένως.
- Η *αναπαράσταση του συμπληρώματος ως προς 2*, στην οποία οι αρνητικοί αριθμοί N αναπαρίστανται ως $2 - |x|$ και μπορεί να υπολογιστεί εύκολα, προσθέτοντας τη μονάδα στο λιγότερο σημαντικό bit του συμπληρώματος ως προς 1. Σε αυτή την αναπαράσταση, το bit του πρόσημου s_x χρησιμοποιείται όπως και πριν. Παρατηρώντας πως για τους αρνητικούς αριθμούς είναι $|x| = -x$, θα έχουμε $2 - |x| = 2 + x$ και κατά συνέπεια, ο αριθμός x μπορεί να διατυπωθεί στη μορφή

$$x = -2 + 1 + x_1 2^{-1} + x_2 2^{-2} + \cdots + x_n 2^{-n} = -1 + x_1 2^{-1} + x_2 2^{-2} + \cdots + x_n 2^{-n} = -s_x + x_1 2^{-1} + x_2 2^{-2} + \cdots + x_n 2^{-n}$$

η οποία είναι ιδιαίτερα χρήσιμη για την παρουσίαση της πράξης του *πολλαπλασιασμού* ανάμεσα σε δύο αριθμούς που αναπαρίστανται χρησιμοποιώντας το συμπλήρωμα ως προς 2. Από την παραπάνω σχέση, προκύπτει επίσης ότι

$$\frac{x}{2} = -s_x 2^{-1} + x_1 2^{-2} + x_2 2^{-3} + \cdots + x_n 2^{-n-1}$$


και επειδή είναι $-s_x 2^{-1} = -s_x + s_x 2^{-1}$, η παραπάνω σχέση γίνεται

$$\frac{x}{2} = -s_x + s_x 2^{-1} + x_1 2^{-2} + x_2 2^{-3} + \cdots + x_n 2^{-n-1} \quad (2)$$

Από την τελευταία έκφραση προκύπτει το συμπέρασμα πως εάν η αναπαράσταση συμπληρώματος ως προς 2 ενός αριθμού x είναι η $s_x x_1 x_2 x_3 \cdots x_n$, τότε η αναπαράσταση συμπληρώματος ως προς 2 του αριθμού $x/2$ είναι η $s_x s_x x_1 x_2 x_3 \cdots x_n$. Με άλλα λόγια, η *διαίρεση με το 2* ενός αριθμού x που είναι εκπεφρασμένος στην αναπαράσταση συμπληρώματος ως προς 2, συνίσταται απλά στην *μετατόπιση όλων των bits του αριθμού κατά μία θέση δεξιά και στην επανάληψη του bit του πρόσημου στην πρώτη από αριστερά θέση*. Αυτή η ιδιότητα απλοποιεί σημαντικά την πράξη του *πολλαπλασιασμού* που χρησιμοποιείται σε αυτόν τον τύπο αναπαράστασης. Μιλώντας γενικά, οι αναπαράστασεις του συμπληρώματος ως προς 1 και ως προς 2 είναι πιο αποτελεσματικές για την πραγματοποίηση *προσθέσεων*, ενώ η αναπαράσταση πρόσημου μεγέθους είναι πιο αποτελεσματική για την πραγματοποίηση *πολλαπλασιασμών*¹. Πάντως, στην εποχή μας ο τύπος της αναπαράστασης που έχει καθιερωθεί, είναι η αναπαράσταση συμπληρώματος ως προς 2.

Όπως έχει ήδη αναφερθεί, αυτοί οι τρεις διαφορετικοί τύποι αναπαράστασης, αφορούν *μόνο στους αρνητικούς αριθμούς*, ενώ οι θετικοί αριθμοί αναπαρίστανται στις τρεις αυτές μορφές αναπαράστασης με τον τρόπο που περιγράψαμε προηγουμένως. Στην πράξη χρησιμοποιείται κατά κύριο λόγο η αναπαράσταση του συμπληρώματος ως προς 2, επειδή αποδεικνύεται πως είναι πιο κατάλληλη για την πραγματοποίηση υπολογισμών. Ένα χαρακτηριστικό αυτής της αναπαράστασης, είναι πως *εάν κατά την πραγματοποίηση προσθέσεων εμφανιστεί κρατούμενο που προκύπτει από το πιο σημαντικό bit, αυτό σε ορισμένες περιπτώσεις αγνοείται* (όπως συμβαίνει στην αφαίρεση $a - b$ που πραγματοποιείται ως $a + (-b)$ και είναι $a \geq b$, όχι όμως και στην αφαίρεση $b - a$), κάτι που *δεν ισχύει* στην αναπαράσταση του συμπληρώματος ως προς 1, όπου το κρατούμενο που προκύπτει προστίθεται στο λιγότερο σημαντικό bit. Από την άλλη πλευρά, στην αναπαράσταση πρόσημου μεγέθους τα πράγματα είναι πιο περίπλοκα, αφού

¹ Δείτε Hwang, K, *Computer Arithmetic: Principles, Architecture and Design*. New York, Wiley, 1979.



Σχήμα 1 Αναπαράσταση σταθερής υποδιαστολής.

εκεί απαιτείται μεταξύ άλλων έλεγχος του πρόσημου του αθροίσματος. Βέβαια, το πλεονέκτημα αυτού του τύπου αναπαράστασης, είναι πως η πραγματοποίηση των πολλαπλασιασμών είναι μία απλή διαδικασία που συνίσταται στον πολλαπλασιασμό των τιμών των δύο αριθμών και στην προσθήκη του πρόσημου, ενώ αντίθετα, στις αναπαραστάσεις του συμπληρώματος ως προς 1 και ως προς 2, τα πράγματα είναι πιο περίπλοκα και ενδέχεται να υπάρξουν περιπτώσεις στις οποίες απαιτείται ειδικός χειρισμός.

Αναπαράσταση κινητής υποδιαστολής

Τα όσα αναφέραμε στην προηγούμενη ενότητα, αποτελούν την επανομαζόμενη αναπαράσταση σταθερής υποδιαστολής, η οποία απεικονίζεται στο Σχήμα 1. Το μειονέκτημα αυτής της αναπαράστασης, η οποία γενικά χρησιμοποιείται όταν το ψηφιακό φίλτρο είναι υλοποιημένο σε υλικό και κατά συνέπεια, χρησιμοποιεί εξειδικευμένο εξοπλισμό όπως είναι οι επεξεργαστές DSP, είναι πως το πλήθος των αριθμών που μπορούν να αναπαρασταθούν, δεν είναι πολύ μεγάλο. Ειδικότερα, ο μικρότερος αριθμός που μπορεί να αναπαρασταθεί χρησιμοποιώντας την αναπαράσταση συμπληρώματος ως προς 2 είναι το -1 , ενώ ο μεγαλύτερος είναι ο $1 - 2^{-L}$. Άλλα δύο μειονεκτήματα αυτής της αναπαράστασης, είναι πως το εκατοστιαίο σφάλμα που επάγεται από την εφαρμογή διαδικασιών κβαντισμού που στηρίζεται στην περικοπή και στην στρογγυλοποίηση (δείτε την επόμενη ενότητα) αυξάνεται με την αύξηση του μεγέθους του αριθμού, ενώ η ανάλυση που υποστηρίζει είναι σταθερή και ίση με $x_{\max} - x_{\min} / (2^{\beta} - 1)$ όπου $x_{\max}$ και $x_{\min}$ είναι η μέγιστη και η ελάχιστη τιμή των αριθμών που επιθυμούμε να κωδικοποιήσουμε, ενώ β είναι το πλήθος των bits που χρησιμοποιούνται για αυτήν την κωδικοποίηση. Ωστόσο, γνωρίζουμε, πως ένας αριθμός μπορεί να γραφτεί με πολλούς διαφορετικούς τρόπους, εάν μετακινήσουμε κατάλληλα προς τα αριστερά ή προς τα δεξιά το σύμβολο της υποδιαστολής και αντίστοιχα πολλαπλασιάσουμε ή διαιρέσουμε την τιμή του αριθμού με την κατάλληλη δύναμη του 10. Για παράδειγμα, ο αριθμός 107.32 μπορεί επίσης να διατυπωθεί ως 10.732×10 , 1.0732×100 , αλλά και ως $1073.2/100$ και $10732/100$. Ανάλογη είναι η κατάσταση και στο δυαδικό σύστημα, αλλά και σε όλα τα αριθμητικά συστήματα. Επειδή αυτοί οι ισοδύναμοι τρόποι γραφής του ίδιου αριθμού, συνίστανται στην μετακίνηση της υποδιαστολής προς τα αριστερά ή προς τα δεξιά κατά το κατάλληλο πλήθος ψηφίων, αυτή η αναπαράσταση είναι γνωστή ως αναπαράσταση κινητής υποδιαστολής. Αυτός ο τύπος της αναπαράστασης χρησιμοποιείται σε όλους τους μοντέρνους ηλεκτρονικούς υπολογιστές και κατά συνέπεια, χρησιμοποιείται σε όλα τα ψηφιακά φίλτρα τα οποία είναι υλοποιημένα σε λογισμικό.

Σε μία πιο λεπτομερή περιγραφή, στην αναπαράσταση κινητής υποδιαστολής και περιοριζόμενοι στο δυαδικό σύστημα που μας ενδιαφέρει, ο κάθε αριθμός L διατυπώνεται στη μορφή $L = M \times 2^E$, όπου M είναι ένας συντελεστής που παίρνει τιμές στην περιοχή $1/2 \leq M < 1$ και E ο εκθέτης της βάσης του δυαδικού συστήματος, ο οποίος μπορεί να είναι ένας θετικός ή ένας αρνητικός ακέραιος. Από τους δύο παραπάνω αριθμούς, ο συντελεστής M είναι ένας κλασματικός αριθμός, ο οποίος μπορεί να θεωρηθεί πως αντιστοιχεί στους κλασματικούς αριθμούς της αναπαράστασης σταθερής υποδιαστολής, ενώ ο εκθέτης είναι ένας ακέραιος αριθμός, ο οποίος αναπαριστά το πλήθος των θέσεων κατά τις οποίες θα πρέπει να μετακινηθεί η υποδιαστολή που εμφανίζεται στον συντελεστή (προς τα αριστερά ή προς τα δεξιά), προκειμένου να προκύψει ο αρχικός αριθμός. Σε αυτή την αναπαράσταση, στην οποία η υποδιαστολή βρίσκεται μετά το δεύτερο πιο σημαντικό bit του συντελεστή, αφού το πρώτο bit αναπαριστά το πρόσημο, αμφότεροι αυτοί οι αριθμοί, απαιτούν ένα bit για την αναπαράσταση του πρόσημου και κατά συνέπεια, ένας πιο λεπτομερής ορισμός της, είναι ο $L = (-1)^S M \times 2^E$ με το bit S να αναπαριστά το πρόσημο και να έχει την τιμή μηδέν για τους θετικούς αριθμούς και την τιμή 1 για τους αρνητικούς αριθμούς. Χρησιμοποιώντας αυτόν τον τύπο αναπαράστασης, οι αριθμοί 0.00110101 και 1001.11 αναπαρίστανται ως 0.110101×2^{-2} και 0.100111×2^4 αντίστοιχα. Στηριζόμενοι στον παραπάνω τύπο περιγραφής, δεν είναι δύσκολο να γίνει αντιληπτό, πως οι καταχωρητές στους οποίους αποθηκεύονται αυτοί οι αριθμοί, είναι διαχωρισμένοι σε τμήματα στα οποία αποθηκεύονται το bit του πρόσημου και οι τιμές του συντελεστή και του εκθέτη με το μήκος αυτών των τμημάτων σε bits να υπαγορεύεται από το εάν η αναπαράσταση είναι μισής, απλής ή διπλής ακρίβειας σύμφωνα με τα όσα αναφέρουμε σε επόμενη ενότητα.

Ένα από τα χαρακτηριστικά της αναπαράστασης κινητής υποδιαστολής, είναι πως η πυκνότητα επί της ευθείας των πραγματικών αριθμών, των αριθμών που αναπαρίστανται κατά αυτόν τον τρόπο, δεν είναι σταθερή, λόγω της ύπαρξης του όρου 2^E που χρησιμοποιείται στην εξίσωση ορισμού αυτής της αναπαράστασης. Αντίθετα, εκείνο που είναι σταθερό είναι το πλήθος των αριθμών κινητής υποδιαστολής που βρίσκονται ανάμεσα σε δύο διαδοχικές δυνάμεις του 2. Για παράδειγμα, το πλήθος των αριθμών που βρίσκονται ανάμεσα στους αριθμούς 16 ($= 2^4$) και 32 ($= 2^5$) είναι το ίδιο με το πλήθος των αριθμών που βρίσκονται ανάμεσα στους αριθμούς 128 ($= 2^7$) και 256 ($= 2^8$). Επειδή όμως η διαφορά $256 - 128 = 128$ είναι μεγαλύτερη από τη διαφορά $32 - 16 = 16$, η απόσταση μεταξύ δύο διαδοχικών αριθμών στην δεύτερη περιοχή τιμών, είναι μεγαλύτερη από την απόσταση ανάμεσα σε δύο αριθμούς που ανήκουν στην πρώτη περιοχή. Γενικεύοντας αυτή την παρατήρηση, μπορούμε να διατυπώσουμε τον ισχυρισμό, πως όσο πιο μεγάλες είναι οι τιμές των αριθμών κινητής υποδιαστολής δηλαδή όσο πιο μεγάλη είναι η τιμή του εκθέτη E , τόσο πιο μεγάλη είναι η απόσταση ανάμεσα σε δύο τέτοιους αριθμούς.

Προκειμένου να κατανοήσουμε στην πράξη αυτό το χαρακτηριστικό, ας προσπαθήσουμε να απαριθμήσουμε τους φυσικούς αριθμούς χρησιμοποιώντας αναπαράσταση κινητής υποδιαστολής με 4 bits για την αποθήκευση του συντελεστή (το πλήθος των bits για τον εκθέτη E δεν μας ενδιαφέρει, διότι το παράδειγμα αφορά λίγο μόνο αριθμούς). Αρχικά η τιμή του εκθέτη είναι $E = 0$ και κατά συνέπεια ο συντελεστής M θα πολλαπλασιαστεί επί $2^0 = 1$. Ξεκινώντας από το 0 και αρχίζοντας να

E = 0		E = 1		E = 2		E = 3		E = 4	
M	L	M	L	M	L	M	L	M	L
0000	0	1000	16	1000	32	1000	64	1000	128
0001	1	1001	18	1001	36	1001	72	1001	144
0010	2	1010	20	1010	40	1010	80	1010	160
0011	3	1011	22	1011	44	1011	88	1011	176
0100	4	1100	24	1100	48	1100	96	1100	192
0101	5	1101	26	1101	52	1101	104	1101	208
0110	6	1110	28	1110	56	1110	112	1110	224
0111	7	1111	30	1111	60	1111	120	1111	240
1000	8	1ος κύκλος		2ος κύκλος		3ος κύκλος		4ος κύκλος	
1001	9	x 2		x 4		x 8		x 16	
1010	10								
1011	11								
1100	12								
1101	13								
1110	14								
1111	15								

Σχήμα 2 Η διαδικασία απαρίθμησης φυσικών αριθμών εκπεφρασμένους στην αναπαράσταση κινητής υποδιαστολής.

μετρούμε, θα φτάσουμε μέχρι την τιμή 15, που είναι η μέγιστη τιμή που μπορεί να κωδικοποιηθεί με 4 bits. Στο σημείο αυτό ολοκληρώνεται ο *αρχικός κύκλος* της διαδικασίας, ο οποίος θα μπορούσε να χαρακτηριστεί ως ο *μηδενικός κύκλος*. Στο επόμενο στάδιο, αυξάνουμε την τιμή του συντελεστή κατά 1 δηλαδή ορίζουμε $E = 1$, κάτι που σημαίνει πως από το σημείο αυτό και μετά, η τιμή του συντελεστή θα πολλαπλασιαστεί επί $2^1 = 2$. Όσον αφορά στην τιμή του συντελεστή, αυτή αρχικοποιείται στην 1000. Αυτή η τιμή στο δεκαδικό σύστημα, είναι η τιμή 8, η οποία πολλαπλασιασμένη επί 2, θα μας δώσει την τιμή 16 που είναι η πρώτη τιμή που δημιουργείται σε αυτόν τον πρώτο κύκλο. Συνεχίζοντας την απαρίθμηση, οι επόμενες τιμές είναι οι 1001, 1010, 1011 (δηλαδή οι 9, 10, 11 και 12) οι οποίες πολλαπλασιασμένες επί 2 θα μας δώσουν τους αριθμούς 18, 20, 22 και 24. Ο τελευταίος αριθμός σε αυτόν τον πρώτο κύκλο είναι ο 1111 (δηλαδή ο 15) που αν πολλαπλασιαστεί επί 2 θα μας δώσει τον αριθμό 30. Στο σημείο αυτό ολοκληρώνεται ο *δεύτερος κύκλος* και δεν είναι δύσκολο να αντιληφθούμε, πως επειδή σε αυτόν τον κύκλο οι τιμές του συντελεστή πολλαπλασιάζονται επί 2 αφενός μεν δεν είναι δυνατή η αναπαράσταση όλων των αριθμών (για παράδειγμα, οι περιττοί αριθμοί δεν αναπαρίστανται) αφετέρου δε, η απόσταση ανάμεσα στους διαδοχικούς αριθμούς έχει διπλασιαστεί. Στη συνέχεια αυξάνουμε την τιμή του συντελεστή E κατά μία μονάδα, δηλαδή εκχωρούμε σε αυτόν την τιμή $E = 2$. Κατά συνέπεια, σε αυτόν τον κύκλο, οι δυνατές τιμές του συντελεστή, ο οποίος αρχικοποιείται εκ νέου στην τιμή 1000 και κατά συνέπεια, είναι οι ίδιες με πριν, δηλαδή οι 1000 (8), 1001 (9), 1010 (10), κ.ο.κ μέχρι την τιμή 1111 (15), θα πολλαπλασιαστούν επί 4 οδηγώντας στους αριθμούς 32, 36, 40, 44, 48, 52, 56, 60. Συνεχίζοντας με τον ίδιο τρόπο, οι τιμές που θα προκύψουν στον τρίτο κύκλο αποτελούν τα γινόμενα των παραπάνω αριθμών επί $2^3 = 8$ και είναι οι 64, 72, 80, 88, 96, 104, 112 και 120. Ακολουθεί ο *τέταρτος κύκλος*, στον οποίο οι τιμές που προκύπτουν είναι οι 128, 144, 160, 176, 192, 208, 224 και 240 (εδώ ο πολλαπλασιασμός πραγματοποιείται επί $2^4 = 16$) κ.ο.κ. Επομένως, στον p αριθμόν p κύκλο και για έναν συντελεστή των 4 bits, οι τιμές που προκύπτουν αποτελούν τα γινόμενα των οκτώ παραπάνω αριθμών επί 2^p . Εάν χρησιμοποιηθεί διαφορετικό πλήθος bits για την κωδικοποίηση της τιμής του συντελεστή, η κατάσταση διαμορφώνεται αναλόγως. Αυτή η διαδικασία απεικονίζεται στο Σχήμα 2 και όπως μπορεί εύκολα να επαληθευτεί, το πλήθος των αριθμών που δημιουργούνται σε κάθε κύκλο, δηλαδή, ουσιαστικά, ανάμεσα σε δύο διαδοχικές δυνάμεις του 2, είναι σταθερό και στην προκειμένη περίπτωση ίσο με 8. Επιπλέον, το γεγονός πως κάποιοι αριθμοί δεν αναπαρίστανται, αυτό δεν θα πρέπει να οδηγήσει στο εσφαλμένο συμπέρασμα, πως υπάρχουν αριθμοί οι οποίοι δεν είναι δυνατόν να αναπαρασταθούν με την αναπαράσταση κινητής υποδιαστολής (αν και μιλώντας αυστηρά, αυτό είναι κάτι που ισχύει, αφού το πλήθος των αριθμών κινητής υποδιαστολής που μπορούν να δημιουργηθούν είναι προφανώς υποσύνολο του άπειρου πλήθους των πραγματικών αριθμών που περιλαμβάνονται στο μη αριθμήσιμο απειροσύνολο $\mathbb{R}$). Εκείνο που εννοούμε είναι πως οι αριθμοί που δεν αναπαρίστανται στο παραπάνω παράδειγμα, μπορούν να αναπαρασταθούν αν χρησιμοποιηθεί μεγαλύτερο πλήθος από bits. Για παράδειγμα, εάν για τον συντελεστή χρησιμοποιήσουμε 5 bits τότε στον μηδενικό κύκλο θα δημιουργηθούν οι αριθμοί 0 έως 31 ανάμεσα στους οποίους περιλαμβάνονται και οι περιττοί αριθμοί που βρίσκονται ανάμεσα στο 16 και στο 30 και οι οποίοι δεν μπορούν να αναπαρασταθούν με 4 bits.

Η σύγκριση ανάμεσα στην αναπαράσταση κινητής υποδιαστολής και στην αναπαράστασης σταθερής υποδιαστολής υπό την προϋπόθεση πως αυτές χρησιμοποιούν το ίδιο πλήθος από bits, οδηγεί στο συμπέρασμα πως η αναπαράσταση κινητής υποδιαστολής επιτρέπει την κωδικοποίηση αριθμών που ανήκουν σε πολύ μεγαλύτερη περιοχή τιμών, μεταβάλλοντας με τον κατάλληλο τρόπο την ανάλυση για την περιοχή τιμών που μας ενδιαφέρει. Αντίστροφα, η αναπαράσταση κινητής υποδιαστολής μπορεί να χειριστεί μία δυναμική περιοχή συγκεκριμένου μεγέθους χρησιμοποιώντας λιγότερα bits σε σχέση με την αριθμητική σταθερής υποδιαστολής. Η παραπάνω ανάλυση ελαττώνεται με την αύξηση του μεγέθους δύο διαδοχικών αριθμών και κατά συνέπεια, η απόσταση ανάμεσα σε δύο πραγματικούς αριθμούς που είναι κωδικοποιημένοι σύμφωνα με την αναπαράσταση κινητής υποδιαστολής, αυξάνεται, καθώς οι αριθμοί αυξάνονται σε μέγεθος. Σε μία εναλλακτική περιγραφή, εάν θέλουμε να καλύψουμε την


ίδια δυναμική περιοχή χρησιμοποιώντας αμφότερες την αναπαράσταση σταθερής υποδιαστολής και την αναπαράσταση κινητής υποδιαστολής, η τελευταία αναπαράσταση προσφέρει μεγαλύτερη ανάλυση για μικρούς αριθμούς αλλά μικρότερη ανάλυση για μεγαλύτερους αριθμούς, ενώ αντίθετα, η αναπαράσταση σταθερής υποδιαστολής προσφέρει την ίδια ανάλυση για όλη την περιοχή τιμών. Ωστόσο, από την άλλη πλευρά, η αναπαράσταση κινητής υποδιαστολής είναι πιο περίπλοκη, αφού πριν την πραγματοποίηση προσθέσεων και πολλαπλασιασμών θα πρέπει να λάβει χώρα ο κβαντισμός της τιμής ου συντελεστή M , ενώ αντίθετα, στην αναπαράσταση σταθερής υποδιαστολής η διαδικασία του κβαντισμού απαιτείται μόνο μετά την πραγματοποίηση των πολλαπλασιασμών. Όσον αφορά στη συμπεριφορά αυτών των δύο αναπαραστάσεων με κριτήριο τον θόρυβο στρωγγυλοποίησης, οι σχετικές έρευνες πάνω στο θέμα αυτό² έχουν δείξει πως η αναπαράσταση κινητής υποδιαστολής είναι *υπέρτερη* της αναπαράστασης σταθερής υποδιαστολής, μόνο για φίλτρα που χαρακτηρίζονται από μεγάλη τιμή του *παράγοντα ποιότητας* Q και χαρακτηρίζονται από υψηλή τιμή κέρδους κάτι που ισχύει ιδιαίτερα για φίλτρα που προκύπτουν από την εν σειρά σύνδεση απλούστερων βαθμίδων. Ωστόσο, όπως εξηγούμε και αλλού, σε αυτά τα φίλτρα είναι πολύ συνηθισμένη η κλιμάκωση των σημάτων που διακινούνται ανάμεσα στις διάφορες βαθμίδες. Για το λόγο αυτό, αρκετές από αυτές τις ψηφιακές διατάξεις χρησιμοποιούν αριθμητική σταθερής υποδιαστολής.

Θεωρώντας δύο αριθμούς που είναι κωδικοποιημένοι σύμφωνα με την αναπαράσταση κινητής υποδιαστολής, ο πολλαπλασιασμός τους πραγματοποιείται πάρα πολύ εύκολα, *πολλαπλασιάζοντας τους συντελεστές και προσθέτοντας τους εκθέτες*, ενώ αντίθετα, η πρόσθεση μπορεί να πραγματοποιηθεί μόνο εάν προηγουμένως μετασχηματίσουμε τους αριθμούς έτσι ώστε αμφότεροι να χαρακτηρίζονται από τον ίδιο εκθέτη. Αυτό είναι κάτι που πραγματοποιείται τροποποιώντας με τον κατάλληλο τρόπο την τιμή του συντελεστή, διαδικασία, η οποία οδηγεί σε *μείωση της ακρίβειας*, ενώ είναι δυνατό να οδηγήσει στην εμφάνιση υπερχειλίσσης και ανεπάρκειας. Επειδή ο τύπος αναπαράστασης της κινητής υποδιαστολής είναι αυτός που χρησιμοποιείται κατά κύριο λόγο στις επιστημονικές εφαρμογές που εκτελούνται στους ηλεκτρονικούς υπολογιστές, η επιστημονική ένωση της IEEE έχει ορίσει ένα πρότυπο και πιο συγκεκριμένα το πρότυπο *IEEE 754*, το οποίο υπαγορεύει τη μορφή των αριθμών που ακολουθούν αυτόν τον τύπο αναπαράστασης. Σύμφωνα με αυτό το πρότυπο, ένας αριθμός έχει τη μορφή $N = S \times 2^{E+B}$. Σε αυτή τη γραφή, ο συντελεστής S είναι ένας *προσημασμένος μικτός αριθμός* που διαθέτει τόσο ακέραιο όσο και κλασματικό μέρος και λαμβάνει τιμή στην περιοχή από 1 έως $2 - 2^{-L}$ όπου L είναι το πλήθος των σημαντικών bits που επιτρέπονται στο κλασματικό μέρος του S , ενώ το μέγεθος B είναι γνωστό ως *πόλωση* και λαμβάνει μόνο ακέραιες τιμές. Είναι ενδιαφέρον να επισημάνουμε, πως εάν ο αριθμός τροποποιηθεί με τον κατάλληλο τρόπο έτσι ώστε η τιμή του S να ανήκει στην περιοχή τιμών από 1 έως $2 - 2^{-L}$, τότε η δυαδική του αναπαράσταση θα έχει πάντα τη μορφή *1.xxxxxxx* και επειδή είναι εγγυημένο πως το ακέραιο μέρος του *είναι πάντα ίσο με τη μονάδα*, αυτό το bit *δεν χρειάζεται να αποθηκευτεί* αφού έχει πάντα την ίδια γνωστή τιμή. Αυτή η δυνατότητα είναι πολύ σημαντική, αφού μπορούμε να αυξήσουμε την ακρίβεια κατά ένα bit, χωρίς κανένα πρόσθετο κόστος σε υλικό. Οι αριθμοί που είναι εκπεφρασμένοι σε αυτή τη μορφή, χαρακτηρίζονται ως *κανονικοποιημένοι*. Από την άλλη πλευρά, η χρήση της πόλωσης, μας απαλλάσσει από την ανάγκη να πραγματευτούμε αρνητικούς αριθμούς κάτι που *απλοποιεί σημαντικά* την αριθμητική αν και καθιστά πιο πολύπλοκη την πραγματοποίηση των πολλαπλασιασμών και των διαιρέσεων, αφού η παρουσία του αριθμού B στον εκθέτη του αριθμού, συνεπάγεται πως στην περίπτωση ενός πολλαπλασιασμού ο εκθέτης του αποτελέσματος θα περιέχει τον αριθμό $2B$ (αφού στον πολλαπλασιασμό οι εκθέτες προστίθενται) και κατά συνέπεια, θα πρέπει να αφαιρέσουμε ένα B , ενώ στην περίπτωση της διαίρεσης, η πόλωση *απαλείφεται* (αφού στην διαίρεση οι εκθέτες αφαιρούνται) και κατά συνέπεια θα πρέπει να προσθέσουμε ένα B . Βέβαια, σε κάθε περίπτωση μπορούμε να χρησιμοποιήσουμε την τιμή $B = 0$, έτσι ώστε να μην χρησιμοποιήσουμε καθόλου αυτό το χαρακτηριστικό. Σύμφωνα με το πρότυπο *IEEE754*, για την αναπαράσταση κινητής υποδιαστολής μπορούν να χρησιμοποιηθούν *τρεις διαφορετικές μορφές*, με την πρώτη μορφή να χρησιμοποιεί 16 bits (1 bit για το πρόσημο, 5 bits για τον εκθέτη και 10 bits για τον συντελεστή) και να είναι γνωστή ως *αναπαράσταση μισής ακρίβειας*, την δεύτερη μορφή να χρησιμοποιεί 32 bits (1 bit για το πρόσημο, 8 bits για τον εκθέτη και 23 bits για τον συντελεστή) και να είναι γνωστή ως *αναπαράσταση απλής ακρίβειας* και την τρίτη μορφή να χρησιμοποιεί 64 (1 bit για το πρόσημο, 11 bits για τον εκθέτη και 52 bits για τον συντελεστή) και να είναι γνωστή ως *αναπαράσταση διπλής ακρίβειας*. Η δομή του αριθμού που ακολουθεί αυτούς τους τρεις διαφορετικούς τύπους αναπαράστασης απεικονίζεται στο Σχήμα 3, στο οποίο φαίνονται οι ομάδες των bits που περιέχουν τις τιμές του εκθέτη και του συντελεστή για αυτές τις τρεις περιπτώσεις. Περισσότερες λεπτομέρειες σχετικά με το θέμα αυτό, όπως είναι η περιοχή τιμών που υποστηρίζεται, καθώς και σχετικές πληροφορίες, μπορούν να βρεθούν στη βιβλιογραφία. Θα πρέπει να σημειώσουμε πως παρά το γεγονός πως η αναπαράσταση κινητής υποδιαστολής *υποστηρίζει μεγαλύτερη δυναμική περιοχή και οδηγεί σε αύξηση της ακρίβειας της επεξεργασίας*, ωστόσο απαιτεί *πιο ακριβό υλικό και πολύπλοκο λογισμικό*, ενώ οδηγεί σε *μείωση της ταχύτητας επεξεργασίας* αφού απαιτείται επεξεργασία των τιμών τόσο του συντελεστή όσο και του εκθέτη.


Επιλογή του κατάλληλου τύπου αναπαράστασης

Η επιλογή του τύπου της αριθμητικής που θα χρησιμοποιηθεί για την υλοποίηση της εξισώσεως διαφορών του ψηφιακού φίλτρου (δηλαδή εάν θα χρησιμοποιηθεί η αναπαράσταση σταθερής ή κινητής υποδιαστολής), αποτελεί έναν από τους πιο σημαντικούς παράγοντες που λαμβάνονται υπόψη κατά τη σχεδίαση ενός τέτοιου συστήματος. Συνήθως, οι περισσότερες αναλύσεις όσον αφορά στην επίδραση του θορύβου, στηρίζονται στην χρήση της *αριθμητικής σταθερής υποδιαστολής* επειδή αυτός ο τύπος της αριθμητικής είναι *πιο απλός* στην υλοποίησή του. Στην περίπτωση κατά την οποία το υποκείμενο ψηφιακό σύστημα χρησιμοποιεί αυτόν τον τύπο της αναπαράστασης, το πλήθος των σημαντικών ψηφίων που χρησιμοποιούνται για την αναπαράσταση των εσωτερικών σημάτων, προσδιορίζει και την *δυναμική περιοχή* του φίλτρου, ενώ επειδή οι τιμές των σημάτων που διακινούνται στο

² Για τη μελέτη της συμπεριφοράς της αναπαράστασης κινητής υποδιαστολής όσον αφορά στο θόρυβο στρωγγυλοποίησης δείτε Liu B & Kaneko T, *Error analysis of digital filters realized with floating-point arithmetic*, Proc. IEEE, vol. 57, pp. 1735-1747, Oct. 1969. Για μία αντίστοιχη μελέτη για την αριθμητική σταθερής υποδιαστολής δείτε Jackson L. B, *Roundoff-noise analysis for fixed - point digital filters realized in cascade or parallel form*, IEEE Tran. Audio Electroacoust vol. AU-18, pp. 107-122, June 1970 ενώ για μία σύγκριση των παραπάνω αποτελεσμάτων δείτε Weinstein C & Oppenheim A.V, *A comparison of roundoff noise in floating point and fixed point digital filter*, Proc. IEEE, vol. 57, DD. 1181-1183. June 1969.



Σχήμα 3 Αναπαράσταση κινητής υποδιαστολής μισής, απλής και διπλής ακριβείας σύμφωνα με το πρότυπο IEEE 754.



Σχήμα 4 Η αναπαράσταση κινητής υποδιαστολής ομάδας δεδομένων.

σύστημα, ενδέχεται να παρουσιάζουν μεγάλες αποκλίσεις ανάμεσα στις διάφορες βαθμίδες, λαμβάνει χώρα σε κάθε βαθμίδα η κατάλληλη *κλιμάκωση του σήματος*, έτσι ώστε να χρησιμοποιηθεί όλο το διαθέσιμο εύρος τιμών της δυναμικής περιοχής της κάθε βαθμίδας αλλά και να αποφευχθεί το φαινόμενο της υπερχειλίσης. Από την άλλη πλευρά, εάν το φίλτρο χρησιμοποιεί *αριθμητική κινητής υποδιαστολής*, η υλοποίηση είναι φυσικά πιο περίπλοκη, αλλά το πλεονέκτημα είναι πως αυτή η κλιμάκωση, όπου απαιτείται, πραγματοποιείται με *αυτόματο* τρόπο. Ειδικότερα, επειδή σε αυτόν τον τύπο αναπαράστασης ο κάθε αριθμός όπως έχουμε δει αναπαρίσταται από έναν συντελεστή και από έναν εκθέτη, οι παράγοντες κλιμάκωσης που χρησιμοποιούνται για αυτόν τον σκοπό, αναπαρίστανται από τους εκθέτες των αριθμών. Αποδεικνύεται πως οι *λόγοι σήματος προς θόρυβο* στα φίλτρα που χρησιμοποιούν αριθμητική κινητής υποδιαστολής, είναι μεγαλύτερος σε σχέση με τα φίλτρα που χρησιμοποιούν αριθμητική σταθερής υποδιαστολής, ενώ εάν το φίλτρο χρησιμοποιεί την αναπαράσταση κινητής υποδιαστολής ομάδας (block floating point), ανακύπτει μία ενδιάμεση κατάσταση. Όσον αφορά στην *ακρίβεια* (precision) που προσφέρει η κάθε αναπαράσταση η οποία ορίζεται ως η *διακριτική ικανότητα της αναπαράστασης* και αποτελεί αναμφίβολα, σημαντικό κριτήριο στην διαδικασία επιλογής του κατάλληλου τύπου αναπαράστασης, αυτή για την μεν αναπαράσταση σταθερής υποδιαστολής, εξαρτάται από το *μήκος λέξης*, για την δε αναπαράσταση κινητής υποδιαστολής, προσδιορίζεται από το *πλήθος των bits του συντελεστή* και ορίζεται ως η *ελάχιστη διαφορά ανάμεσα σε δύο αριθμούς που διαθέτουν τον ίδιο εκθέτη*.

Ας αναφέρουμε για λόγους πληρότητας και ορισμένα πράγματα όσον αφορά σε αυτόν τον τελευταίο τύπο αναπαράστασης. Το βασικό χαρακτηριστικό και ταυτόχρονα πλεονέκτημα της αναπαράστασης κινητής υποδιαστολής ομάδας, είναι η επίτευξη της δυναμικής περιοχής (η οποία ορίζεται ως ο λόγος ανάμεσα στον μικρότερο και στον μεγαλύτερο αριθμό που μπορεί να αναπαρασταθεί σε αυτόν τον επεξεργαστή) η οποία υποστηρίζεται από τους επεξεργαστές κινητής υποδιαστολής, χρησιμοποιώντας όμως επεξεργαστές σταθερής υποδιαστολής. Σημειώστε, πως αν και αυτό είναι κάτι το οποίο μπορεί να επιτευχθεί, χρησιμοποιώντας λογισμικό εξομοίωσης υπολογισμών κινητής υποδιαστολής σε επεξεργαστές σταθερής υποδιαστολής, ωστόσο, αυτή η λύση χαρακτηρίζεται από υψηλές υπολογιστικές απαιτήσεις και ενδείκνυται μόνο σε περιπτώσεις κατά τις οποίες μόνο ένα μικρό τμήμα του συνόλου των υπολογισμών απαιτεί εκτεταμένη δυναμική περιοχή. Ειδικότερα, σε αυτόν τον τύπο αναπαράστασης που έχει προταθεί από τον Orpenheim, οι αριθμοί που χρησιμοποιούνται τοποθετούνται σε μία ομάδα και στη συνέχεια, οι εκθέτες τους προσαρμόζονται με τέτοιο τρόπο, ώστε όλοι αυτοί οι αριθμοί να διαμοιράζονται τον ίδιο κοινό εκθέτη, ο οποίος αποθηκεύεται για μία και μοναδική φορά σε μία και μοναδική λέξη και χρησιμοποιείται για όλους αυτούς τους αριθμούς (δείτε το Σχήμα 4). Η τιμή αυτού του εκθέτη προσδιορίζεται από το στοιχείο εκείνο της ομάδας που χαρακτηρίζεται από το μεγαλύτερο μέγεθος. Αυτή η λύση η οποία χρησιμοποιείται σε περιπτώσεις κατά τις οποίες δεν είναι δυνατή η αξιόπιστη αναπαράσταση των δεδομένων μέσω της σταθερής υποδιαστολής, βρίσκει πάρα πολλές εφαρμογές στον χώρο της ψηφιακής επεξεργασίας σήματος, με την πιο χαρακτηριστική από αυτές, να σχετίζεται με την υλοποίηση του γρήγορου μετασχηματισμού Fourier (δείτε για παράδειγμα David & Iovescu, 2003). Επειδή αυτή η προσέγγιση στηρίζεται σε λογισμικό, η μετατροπή από την αναπαράσταση σταθερής υποδιαστολής στην αναπαράσταση κινητής υποδιαστολής ομάδας, αποτελεί καθήκον του προγραμματιστή.

Επιστρέφοντας στην σύγκριση ανάμεσα στις αναπαραστάσεις σταθερής και κινητής υποδιαστολής, οι επεξεργαστές που χρη-

σιμοποιούν αναπαράσταση σταθερής υποδιαστολής, επιτρέπουν τη χρήση αριθμών *είτε σε κλασματική μορφή* (όπως είναι, για παράδειγμα, αυτοί που χρησιμοποιούνται σε *εφαρμογές επεξεργασίας σήματος*), *είτε σε ακέραια μορφή* (όπως είναι, για παράδειγμα, αυτοί που χρησιμοποιούνται σε *διαδικασίες υπολογισμού διευθύνσεων*). Από την άλλη πλευρά, το βασικό πλεονέκτημα των επεξεργαστών που στηρίζονται στην αναπαράσταση κινητής υποδιαστολής, είναι πως το υλικό του επεξεργαστή είναι σε θέση να προχωρήσει *σε αυτόματη κλιμάκωση* των τιμών των αριθμών, έτσι ώστε να χρησιμοποιηθεί το σύνολο των bits που χρησιμοποιείται για την αποθήκευση της τιμής του συντελεστή. Αυτό σημαίνει, πως εάν μία τιμή είναι υπερβολικά μεγάλη και δεν μπορεί να αναπαρασταθεί από αυτό το πλήθος των bits που χρησιμοποιούνται, το υλικό είναι σε θέση να προχωρήσει *σε κλιμάκωση προς τα κάτω*, πραγματοποιώντας την κατάλληλη μετατόπιση προς τα δεξιά, ενώ στην αντίθετη περίπτωση, κατά την οποία η τιμή του συντελεστή δεν χρησιμοποιεί το συνολικό διαθέσιμο πλήθος των bits, λαμβάνει χώρα *κλιμάκωση προς τα επάνω*, μέσω της κατάλληλης μετατόπισης προς τα αριστερά. Στην περίπτωση αυτή, ο εκθέτης, όπως αναφέραμε, διατηρεί την τιμή του πλήθους των μετατοπίσεων της υποδιαστολής προς την κατάλληλη κατεύθυνση.